


r²-bench 真实多轮轨迹

用户在左 · 智能体 / 工具 / 数据库在右

任务：恢复境外移动数据 | 环境：Telecom | 轨迹：2 轮



用户确认移动数据已恢复 | terminal reward $R = 1$

轮次级信用分配

稀疏结果奖励 → R2G → 反事实信息增益

同一条多轮轨迹

第 1 轮 · a_1, o_1

第 t 轮 · a_t, o_t

第 N 轮 · 终止奖励 R

外部奖励路径

结果奖励

终点标量 R 评价整条轨迹

累积回报 R2G ($\gamma = 0.8$)

$$G_t = r_t + \gamma G_{t+1}$$

.38 .74 1.44 1.0

沿时间反向折扣，前传终点功劳

InfoPO 反事实信息增益

事实分支

保留真实观测 o_t

prompt + o_t

$P_{fact}(a)$

遮蔽分支

$o_t \rightarrow [\text{pad}]...$

prompt + [pad]

$P_{mask}(a)$

$$gain_t = KL(P_{fact} \parallel P_{mask})$$

KL 越大， o_t 的边际价值越高

方差门控

$\text{Var}(\text{组内奖励}) < \tau \rightarrow$ 启用信息增益

否则 $w = 0$ ，保持外部奖励不变

$$A_t = A_t^{\text{reward}} + w \cdot A_t^{\text{gain}}$$

零方差组

恢复非零梯度

组级归一化 → 轮次级信用

$$\text{normalize_group}(G_t \text{ or } gain_t) \rightarrow A_t^{\text{credit}}$$

在 rollout group 内统一归一化，而非单条轨迹内部

行为正则化策略优化

行为塑形 → 优势估计 → TOKEN 级 PPO 更新

A 轮次级信用信号

输入： A_t^{credit} / 塑形奖励 / 损失掩码

行为塑形

BAO · 减法正则

- 连续两轮询问用户

- 失败且过早终止

$p_{\text{info}} + p_{\text{think}} \rightarrow \text{shaped_reward}$

PPP · 加法目标

+ 任务完成度 (Productivity)

+ 主动性 + 个性化

$$R = R_{\text{Prod}} + R_{\text{Proact}} + R_{\text{Pers}}$$

优势估计器

GRPO · $(r - \mu) / (\sigma + \epsilon)$

RLOO · leave-one-out

PPO · $GAE(\gamma, \lambda)$

Token 级 PPO 裁剪损失

$$\rho_t = \exp(\log \pi \theta - \log \pi_{\text{old}})$$

$$L = -E[\min(\rho_t A_t, \text{clip}(\rho_t, 1 - \epsilon, 1 + \epsilon) A_t)]$$

多轮 PPO 冻结旧 log-prob; 当 $\rho \neq 1$ 后裁剪生效

仅 mask=1 的 token 计入损失

DAPO 四组件

Clip-Higher

动态采样

Token 级损失

超长响应塑形

反向传播 → 梯度裁剪 → 参数更新